

DevGuard: 小鼠胚胎扰动细胞的阶段特异发育正常性判定框架

DevGuard working draft

2026-05-05

拟定英文题目

DevGuard: stage-specific developmental normality boundaries for perturbed mouse embryonic cells

一句话主张

DevGuard 学习小鼠每个发育时间点和谱系的正常范围，并用 conformal calibration 判断扰动细胞是仍然正常、发育延迟、发育提前、命运偏航，还是成为正常图谱外异常状态。

路线边界

新版 DevGuard 是独立的小鼠发育扰动正常性判定项目。它不使用 RDEG pipeline、RDEG-derived node graph、OT transition、GRN dynamics 或 matrix-writeback outputs。旧版 DevVCell response-recovery 原型已经归档到：

`Old/legacy_devvcell_response_recovery_20260505/`

当前 quick/stress fixture 结果只用于软件验证。真实论文主结论必须来自独立公开小鼠数据，并经过 sample-level split、heldout control FPR、organoid heterogeneity control 和 perturbation/control 对比。

方法概述

对 control mouse embryo 或 gastruloid time-course, DevGuard 按时间点 t 和谱系 l 建立正常参考集：

$$N(t, l) = \{x_i : x_i \text{ is a control cell at time } t \text{ and lineage } l\}.$$

每个正常参考集被划分为 training、calibration 和 heldout test。真实数据优先使用 embryo/organoid/sample-level split，只有在 sample 数不足时才退化到 cell-level fallback，并在 quality table 中标记。

Embedding

MVP 使用可审计的浅层 embedding:

1. library-size normalization;
2. log1p;
3. high-variance gene selection;
4. TruncatedSVD latent embedding。

Nonconformity score

当前实现两类 score。

KNN distance

$$s_{\text{knn}}(x; t, l) = \frac{1}{k} \sum_{j \in KNN_k(x, N_{\text{train}}(t, l))} \|z_x - z_j\|_2.$$

Mahalanobis distance

$$s_{\text{mah}}(x; t, l) = (z_x - \mu_{t,l})^\top \Sigma_{t,l}^{-1} (z_x - \mu_{t,l}).$$

Conformal p-value

对 query cell x , 相对于 stage-lineage reference $N(t, l)$ 的 conformal p-value 为:

$$p(x; t, l) = \frac{1 + \#\{s_i^{\text{cal}} \geq s(x; t, l)\}}{1 + n_{\text{cal}}}.$$

若 $p(x; t, l) \geq \alpha$, 则认为 x 仍在该 stage-lineage 正常范围内。当前 MVP 默认 $\alpha = 0.05$ 。

扰动细胞分类

DevGuard 对每个 perturbed cell 同时计算:

1. 当前时间、同谱系: p_current_same;
2. 早期时间、同谱系: p_early_same;
3. 晚期时间、同谱系: p_late_same;
4. 其他谱系: p_other_lineage;
5. 任意正常参考: p_any_normal。

分类优先级为:

`within_stage_normal > developmental_delay > developmental_acceleration > fate_deviation > abnormal_off_normal`

为避免过度解释边界细胞, 当前代码同时输出:

`assigned_class_by_priority`
`assigned_class_by_max_pvalue`
`pvalue_margin`
`ambiguous_flag`
`n_candidate_classes_passing_alpha`

Developmental Tolerance Index

对每个 time point、lineage 和 perturbation, 定义:

$$DTI = R_{\text{normal}} - R_{\text{delay}} - R_{\text{accel}} - R_{\text{deviation}} - R_{\text{abnormal}}.$$

当前实现已加入 bootstrap confidence interval。若有多个 `sample_id`, 则优先 sample-level bootstrap; 若只有一个 sample, 则退化为 cell-level bootstrap, 并在输出中记录 `bootstrap_level`。

当前实跑结果

Quick fixture

Quick fixture 用于验证代码路径和五类分类逻辑。

项目	数值
control cells	1,350
perturbed cells	120
genes	90
reference groups	9
score-method records	18
mean heldout FPR	0.0019
max heldout FPR	0.0333

五类 perturbed cells 各 24 个, 分别被分到 `within_stage_normal`、`developmental_delay`、`developmental_acceleration`、`fate_deviation` 和 `abnormal_off_normal`。

Stress fixture

Stress fixture 在 quick fixture 之外加入 Poisson/gamma count noise、batch shift、donor shift、cell-to-cell variation、dropout、ambiguous intermediate cells 和 label noise。

项目	数值
mean heldout FPR	0.0351
max heldout FPR	0.2162
within-stage normal cells	259
fate-deviation cells	19
developmental-delay cells	9
developmental-acceleration cells	1

该结果说明干净 synthetic fixture 会低估 boundary failure risk，因此正式论文必须使用真实 sample-level split。

GSE212050 strict sample-level control reference

GSE212050 已下载 Seurat RDS, 并在完整元数据中筛选能形成严格 sample-level train/cal/test 的 stage-lineage 组。筛选条件为每组至少 200 cells、至少 8 个 sample units，每组最多均衡抽取 1,500 cells，并禁止 cell-level fallback。

项目	数值
cells	13,285
genes	30,406
reference groups	9
score-method records	18
split strategy	sample-level only
cell fallback groups	0
low-heldout records	0 / 18
mean heldout FPR	0.0487
max heldout FPR	0.0723

严格 sample-level rerun 的平均 heldout FPR 接近 $\alpha = 0.05$, 最大 FPR 从早期随机 downsample 的 0.3333 降到 0.0723。所有 reference groups 均使用独立 sample units 进行 train/calibration/test split, 且 `low_heldout_flag=False`。这组结果可作为当前真实 control calibration 的主结果，但正式论文仍应在完整数据或更大采样上复核。

MouseGastrulationData WT/Tal1 chimera smoke test

Bioconductor `MouseGastrulationData` 已安装, 并已导出 embryo atlas sample 1、WT chimera sample 1 和 Tal1 chimera sample 1。WT chimera sample 1 用于 control reference, Tal1 chimera sample 1 用于真实 perturbation classification smoke test。

WT chimera reference 项目	数值
reference groups	12
score-method records	24
mean heldout FPR	0.0294
max heldout FPR	0.1389
split strategy	cell fallback

Tal1 classification smoke test:

class	cells	fraction
fate_deviation	9,325	0.6322
developmental_delay	4,862	0.3296
abnormal_off_normal	564	0.0382

Ambiguity output:

ambiguous flag	cells	fraction
False	11,721	0.7946
True	3,030	0.2054

这组数值不能作为 Tal1 生物学结论, 因为目前只导出一个 WT chimera 样本, 无法形成独立 embryo-level split。

GSE123187 spatial/tomo preview

GSE123187 RAW tar 已下载, 并新增 tar parser 生成 4-file preview H5AD。

项目	数值
cells	1,536
genes	24,086
samples	4
time point	5dAA
mode	single gastruloid

当前 preview 缺少 cell type/lineage 注释, 因此只能作为 spatial/tomo 数据入口验证, 不能直接用于 fate deviation validation。

当前文件与验证

核心代码:

```
src/devguard/  
scripts/devguard/  
config/devguard/  
docs/DEVGUARD_RESULTS_REPORT_CN.md
```

验证命令:

```
python -m pytest
```

当前结果:

```
12 passed
```

下一步

1. 导出完整 MouseGastrulationData embryo atlas、WT chimera、Tal1 chimera 和 T chimera;
2. 对真实数据强制 embryo/organoid-level split, 并过滤低 sample-unit group;
3. 用完整 GSE212050 做 leave-one-organoid-out false-positive calibration;
4. 为 GSE123187 补充 spatial/tomo axis 和 lineage mapping;
5. 所有 perturbation 结论必须与 heldout control FPR 和 organoid heterogeneity FPR 对比后再进入正式 manuscript。