

发育虚拟细胞 DevVCell-lite: 复用 RDEG 数据资产的正式工作计划与初次执行报告

从阶段重建转向细胞级刺激响应、反馈恢复和发育脆弱性图谱

2026 年 5 月 2 日

摘要

本文档围绕 DevVCell 的科学动机、原型分析和最新 OT+GRN 解释性补充展开。原 RDEG 工作已围绕多阶段小鼠胚胎单细胞图谱完成节点构建、相邻阶段最优传输、GRN 动力学、扰动模拟和 rollout 验证。DevVCell 不把 RDEG 作为简单扩展，而是提出一个新的计算对象：可初始化、可刺激、可反馈、可连续推演的发育虚拟细胞。当前原型先复用 RDEG 的已有结果，建立阶段脆弱性、扰动优先级、反馈成本和虚拟细胞响应 proxy 等指标。第一次分析共纳入 16 个 Theiler stages 和 49 个 TF 候选，最高脆弱性阶段为 Theiler stage 15，TS14–TS19 窗口的平均脆弱性分数约为窗口外的 1.38 倍，最高扰动优先级候选为 Satb2。进一步的 OT+GRN 补充分析表明，调控作用可以落到 erythroid、myoblast、primitive erythroid、neural 和 cardiac muscle 等具体系统，从而把 TF–target 边与可解释的发育过程联系起来。

1 现有数据与方法基础

本次补充建立在既有 RDEG 结果之上，而不是另起一个预测框架。现有分析已经完成多阶段小鼠胚胎单细胞图谱的系统选择、节点构建、相邻阶段 OT、GRN 动力学、TF 扰动、rescue、rollout 和矩阵回写。它提供了三类可以继续解释的证据：第一，相邻 Theiler stages 之间的低代价群体重排；第二，能够解释节点表达更新的 TF–target 调控边；第三，扰动、命运信息量和阶段敏感性等后验读出。

因此，本报告的重点不是说明数据和文件如何组织，而是回答一个更接近生物学的问题：在低代价群体重排和局部调控动力学耦合的过程中，哪些转录因子的调控作用最可能影响特定发育系统、细胞类型和生物过程。

2 研究动机

现有 RDEG 工作可以回答：

胚胎阶段之间的细胞群体如何通过低代价路径完成重排，GRN 动力学如何解释这种重排。

DEVCELL 要回答的问题不同：

给定一个具体细胞状态，如果它在某个 Theiler stage 受到基因、通路或环境刺激，它会如何偏离正常轨迹，是否能够通过反馈恢复，又是否会进入替代命运。

因此，新项目的核心对象不是阶段节点或群体流，而是一个可初始化、可刺激、可推演的虚拟细胞 agent。这个 agent 的长期目标是输出细胞表达矩阵、命运概率、恢复成本、发育脆弱性和实验优先级。

3 中心假说

本文采用以下中心假说：

多阶段胚胎单细胞图谱不仅可以用于重建阶段之间的群体流向，还可以训练一个细胞级虚拟模拟器。该模拟器把正常发育视为低代价传输路径，把刺激视为对细胞状态的外部偏移，把反馈视为 GRN 与发育流形共同施加的恢复力；因此，它可以预测单个细胞在不同阶段、不同扰动下的响应、恢复和命运偏移。

这个假说拆成三个可执行层次：

1. 正常发育不是随机跳变，而是沿相邻阶段之间的低代价路径演化。
2. 刺激会把细胞推离正常发育流形，且不同阶段的可偏离程度不同。
3. 反馈恢复不是简单回到原点，而是在 GRN 约束、发育流形和刺激压力之间寻找一个低成本可行状态。

4 DevVCell-lite 的最小可行路线

完整 DEVCELL 将来需要训练 cell encoder、transition operator、stimulus module、GRN feedback head 和 decoder。当前 DEVCELL-lite 先不直接训练深度模型，而是执行一个低风险原型：

1. 复用 RDEG 已经生成的 stage module、TF perturbation、temporal sensitivity、rollout error 和 rescue 表。
2. 将这些表转换为 DEVCELL 的指标语言。
3. 形成三个核心结果表：stage vulnerability、perturbation priority、virtual cell rollout proxy。

4. 生成四张初始图：阶段脆弱性、扰动优先级、反馈成本-响应幅度散点图、正常发育模块步长。
5. 在文档中明确标注当前结果是 prototype/proxy，不等同于真实扰动实验结论。

5 指标设计

5.1 阶段脆弱性

阶段脆弱性分数定义为：

$$V_s = w_1 \tilde{S}_s + w_2 \tilde{E}_s + w_3 \tilde{D}_s + w_4 \tilde{O}_s + w_5 \tilde{M}_s, \quad (1)$$

其中：

- $\tilde{S}_s$ 为阶段平均 TF sensitivity 的归一化值；
- $\tilde{E}_s$ 为多步 rollout 误差的归一化值；
- $\tilde{D}_s$ 为阶段模块均值到下一阶段的正常发育步长；
- $\tilde{O}_s$ 为节点 outlier ratio；
- $\tilde{M}_s$ 为 next-step MSE；
- 当前权重为 0.30, 0.25, 0.20, 0.10, 0.15。

5.2 扰动优先级

扰动优先级分数定义为：

$$P_g = \alpha_1 \tilde{A}_g + \alpha_2 \tilde{L}_g + \alpha_3 \tilde{W}_g + \alpha_4 \tilde{F}_g + \alpha_5 \tilde{Q}_g, \quad (2)$$

其中：

- $\tilde{A}_g$ 为 TF knockout 的 global effect score；
- $\tilde{L}_g$ 为 developmental delay score；
- $\tilde{W}_g$ 为 TS14–TS19 窗口内 sensitivity；
- $\tilde{F}_g$ 为 feedback cost；
- $\tilde{Q}_g$ 为 log mass shift；
- 当前权重为 0.35, 0.20, 0.20, 0.15, 0.10。

反馈成本和恢复概率的 proxy 定义为：

$$C_{\text{feedback}}(g) = 1 - r_g, \quad (3)$$

$$P_{\text{recovery}}(g) = \exp(-2.5 \cdot \tilde{C}_{\text{feedback}}(g)), \quad (4)$$

其中 r_g 是当前 rescue 表中观察到的最佳 rescue fraction。

6 分析工作概述

本次工作的执行重点可以概括为五步：先将已有 RDEG 派生结果转化为阶段脆弱性、扰动优先级和反馈恢复 proxy；随后检查 TF-target 调控边是否具有系统特异性；再将 TF knockout、temporal sensitivity、fate mutual information 和 hub 程度合并为解释性证据；最后把结果写成可进入正文的生物学叙事。整个过程只作为原 OT+GRN 框架的解释层，不新增预测模型。

任务拆解见表 1。

表 1: DevVCell-lite 分析任务拆解

任务	说明	状态
数据基础	复用多阶段胚胎单细胞图谱和既有 RDEG 派生结果。	已完成
OT 结果读出	汇总阶段转移、rollout 误差和发育窗口敏感性。	已完成
GRN 结果读出	汇总 TF-target 边、系统特异边和 hub 程度。	已完成
扰动证据整合	汇总 TF knockout、rescue、temporal sensitivity 和 fate mutual information。	已完成
阶段脆弱性	汇总 sensitivity、rollout error、module step、outlier 和 next-step MSE。	已完成
扰动优先级	汇总 knockout effect、delay、window sensitivity、feedback cost 和 mass shift。	已完成
rollout proxy	用阶段模块步长、阶段脆弱性和 top TF 响应构造虚拟细胞响应 proxy。	已完成
系统发育影响	解释 TF 调控边主要落在哪些系统、细胞类型和生物过程。	已完成
正式 cell-level 模型	接入 H5AD 子集、encoder、OT pseudo target、transition、stimulus 和 feedback head。	下一阶段

7 第一次执行结果

7.1 执行概况

第一次原型分析已经完成，摘要如下：

- 纳入阶段数：16；
- 纳入 TF 候选数：49；
- 最高脆弱性阶段：Theiler stage 15；
- TS14–TS19 平均脆弱性分数：0.5051；
- 窗口外平均脆弱性分数：0.3666；
- TS14–TS19 与窗口外比值：1.3777；
- 最高扰动优先级候选：Satb2；
- Satb2 的 DevVCell priority score：0.8486；
- Satb2 的最佳 rescue TF：Zbtb16；
- Satb2 的 best rescue fraction：0.1214。

7.2 阶段脆弱性初始结果

表 2 列出当前 prototype 分数最高的阶段。需要注意，Theiler stage 12 也较高，主要来自较大的模块步长和 next-step MSE；而 TS14–TS19 作为窗口整体平均值高于窗口外，支持后续把该窗口作为发育敏感窗口继续检查。

表 2: DevVCell-lite 阶段脆弱性初始结果

阶段	分数	窗口	rollout 误差	解释
Theiler stage 15	0.6049	TS14–TS19	0.000323	当前最高脆弱性阶段，处于重点敏感窗口。
Theiler stage 12	0.6012	outside	0.000174	早期模块步长和 next-step MSE 较高，需要单独解释。
Theiler stage 14	0.5871	TS14–TS19	0.000337	处于窗口起点，rollout 误差较高。
Theiler stage 16	0.5211	TS14–TS19	0.000320	与 TS15 连续形成高脆弱区段。
Theiler stage 19	0.5167	TS14–TS19	0.000261	窗口后段仍保持较高分数。

7.3 扰动优先级初始结果

表 3 列出当前扰动优先级前五名。该结果用于后续模型训练和实验设计优先级，不直接等同于真实 knockout 实验结论。

表 3: DevVCell-lite 扰动优先级初始结果

TF	priority	feedback cost	peak stage	当前解释
Satb2	0.8486	0.8786	Theiler stage 23	全局效应和质量偏移最高，已有 Zbtb16 rescue proxy。
Rfx4	0.7101	0.7908	Theiler stage 14	peak stage 落在 TS14，适合敏感窗口案例。
Eya1	0.6875	0.9661	Theiler stage 25	rescue fraction 低，反馈成本高。
Lef1	0.6670	1.0000	Theiler stage 12	与 Wnt/neural 叙事相容，但当前 rescue 未观察到。
Prox1	0.6226	1.0000	Theiler stage 17	peak stage 位于 TS14–TS19 窗口内。

7.4 图件结果




图 1: DevVCell-lite 阶段脆弱性 prototype。红色为 TS14–TS19 窗口，蓝色为窗口外阶段。




图 2: DevVCell-lite 扰动优先级前 12 名。

8 补充分析：用原 OT+GRN 解释调控因子影响哪些系统和细胞发育

8.1 分析目的

根据新的讨论,本项目不需要在这里新增预测方法。更合适的做法是直接利用原 RDEG 的 OT+GRN 结果回答一个解释性问题:

既然模型已经学习到 TF-target 调控边,那么这些调控作用在协调演化过程中是否集中影响了某些发育系统、某些细胞类型或某些具体发育生物过程?

因此,本节把原有结果表重新组织为一个“发育影响解释层”。它不是新模型,也不训练新的 predictor,而是把以下已有证据合并解读:

1. **OT 约束下的阶段转移**: 相邻阶段的低代价传输给出协调演化背景。
2. **GRN 学到的 TF-target 边**: 给出直接调控靶基因和边权。
3. **系统特异调控边**: 给出 TF-target 边在哪些系统或细胞类型中更突出。
4. **TF knockout 结果**: 给出全局效应、发育延迟和质量偏移。
5. **TF-fate 信息量**: 给出 TF 与预测命运之间的信息关联。

换言之,本节回答的不是“能不能用一个新方法预测细胞”,而是“原 OT+GRN 模型已经预测和解释的发育过程,具体落在了哪些系统、细胞和调控模块上”。

8.2 实现方式

该补充只读取原有 RDEG 输出,不读取完整 H5AD,不训练新参数。为了便于排序,我们计算了一个解释性证据汇总分数:

$$E_{\text{OT+GRN}} = 0.35S_{\text{system-edge}} + 0.20S_{\text{KO}} + 0.15S_{\text{temporal}} + 0.15S_{\text{fateMI}} + 0.10S_{\text{hub}} + 0.05S_{\text{GRN-weight}} \quad (5)$$

这个分数只是把已有 OT+GRN 证据合并排序的解释性指标,不代表新的预测模型。它的作用是帮助读者看清:一个 TF 的调控边是否在某个系统中集中、这个 TF 的 knockout 是否有全局影响、它是否与命运预测有关、它是否是网络 hub。

8.3 系统层面的结果

表 4 显示，原 OT+GRN 结果中系统特异调控边最集中的是 erythroid progenitor cell、myoblast、primitive erythroid progenitor、neural cell 和 cardiac muscle cell。这说明原方法不仅能给出阶段重排和 TF-target 边，还能把调控作用落到具体发育系统。

表 4: 原 OT+GRN 结果读出的系统/细胞发育影响

系统或细胞类型	TF 数	边数	主要 TF
erythroid progenitor cell	20	128	Eya1; Lef1; Prdm16; Eya4; Satb2; Pax3; Nrg1; Dach2
myoblast	20	128	Eya1; Dach2; Lef1; Satb2; Satb1; Eya4; Ebf2; Pax3
primitive erythroid progenitor	19	123	Eya1; Zbtb16; Lef1; Pax3; Satb1; Dach2; Satb2; Nrg1
neural cell	20	119	Eya1; Satb2; Dach2; Prdm16; Eya4; Lef1; Pax3; Satb1
cardiac muscle cell	20	112	Satb2; Eya1; Pax3; Eya4; Prdm16; Satb1; Dach2; Lef1
myotube	20	118	Satb2; Eya1; Dach2; Lef1; Eya4; Prdm16; Satb1; Bcl11b
muscle precursor cell	20	114	Eya1; Dach2; Satb2; Eya4; Zbtb16; Pax3; Prdm16; Lef1
hematopoietic stem cell	20	101	Satb2; Eya1; Dach2; Lef1; Prdm16; Eya4; Satb1; Pax3

8.4 TF 层面的结果

表 5 显示，Eya1、Lef1、Prdm16、Satb2、Zbtb16、Dach2、Pax3、Satb1 和 Eya4 是当前最适合写成生物学解释案例的 TF。原因不是它们在单一表里排名靠前，而是它们同时具有若干层证据：系统特异调控边集中、GRN 直接靶基因明确、knockout 或 temporal sensitivity 有响应、部分 TF 还与 fate mutual information 显著相关。

表 5: 原 OT+GRN 证据支持的 TF-系统影响摘要

TF	系统数	最强系统/细胞类型	证据分数	生物学解释
Eya1	8	erythroid progenitor cell	0.7566	同时影响 erythroid、primitive erythroid、neural 和 myoblast，像是跨系统协调因子。
Lef1	8	erythroid progenitor cell	0.6439	与 Wnt/FGF 叙事一致，同时在多个系统中有特异边，可能连接信号通路 with 命运转换。
Prdm16	7	erythroid progenitor cell	0.6289	在 erythroid 和 neural/muscle 相关系统中均有边，可能连接代谢/应激和发育状态转换。
Satb2	8	cardiac muscle cell	0.5974	系统边覆盖 cardiac muscle、myotube、neural 等，适合解释结构重塑和分化成熟。
Zbtb16	8	primitive erythroid progenitor	0.5827	在 primitive erythroid 和 neural 中有系统边，可能与早期命运稳定和分支选择有关。
Dach2	8	myoblast	0.5745	在 myoblast、neural 和 erythroid 中均突出，适合解释肌生成与神经/胚层模块耦合。
Pax3	8	primitive erythroid progenitor	0.5513	GRN 中直接调控 Nrg1/Lef1 等节点，系统层面连接 primitive erythroid、cardiac 和 muscle precursor。
Satb1	8	primitive erythroid progenitor	0.5396	与 primitive erythroid、myoblast 和 neural 的系统边共同支持其分化状态调节作用。
Eya4	8	erythroid progenitor cell	0.5347	与 Eya1 类似，可能处于 Eya family 相关的跨系统调控模块。

8.5 可写进论文的生物过程叙事

这部分结果可以把原方法的生物学解释从“TF knockout 有效”提升到“TF 通过哪些调控边影响哪些系统发育”。建议写成三条主线。

第一，造血/红系发育是最强系统信号之一。 在系统汇总中，erythroid progenitor cell 和 primitive erythroid progenitor 位列前列，主要 TF 包括 Eya1、Lef1、Prdm16、Zbtb16、Pax3、Satb1、Satb2 和 Nrg1。这说明原 OT+GRN 框架不仅在 neural MVP 上工作，也能读出红系/造血状态中较强的调控集中性。生物学上可以解释为：在胚胎协调演化过程中，红系细胞状态具有明显的命运推进和调控稳定需求，因此 TF-target 网络的系统特异边更集中。

第二，肌生成与心肌/骨骼肌成熟构成第二条主线。 myoblast、myotube、muscle precursor cell 和 cardiac muscle cell 均有大量系统特异边。Satb2、Dach2、Eya1、Lef1、Pax3、Eya4 和 Prdm16 在这些系统中反复出现。结合 target 例子中的 *Myl2*、*Tbx15*、*Adam12*、*Smoc1*、*Frem1*、*Svep1* 等，可以把这条主线解释为 mesoderm-to-muscle specification、myogenic commitment、muscle fiber maturation 和 cardiac muscle differentiation 的调控影响。

第三，神经系统不是单独孤立的一条线，而是与红系和肌系共享部分调控因子。 neural cell 中突出的 TF 包括 Eya1、Satb2、Dach2、Prdm16、Eya4、Lef1、Pax3 和 Satb1。结合 GRN 中 Lef1-Fgf15、Pax3-Nrg1、Bcl11b-Cntnap2、Rorb-Epha5、Otx2-Cdh8 等直接边，可以把 neural 结果解释为 Wnt/FGF signaling、neural patterning、cell adhesion/axon guidance 和 neuronal differentiation。更重要的是，这些 TF 并不只在 neural 系统中出现，而是跨 erythroid、muscle 和 cardiac 系统出现，支持“协调演化”中共享调控模块的概念。

8.6 对可验证 TF 的解释价值

之前讨论的可验证 TF 不应只写成“敲掉以后有全局效应”。更好的表述是：

这些 TF 的扰动之所以值得验证，是因为它们在 OT 约束的发育转移背景下，具有明确的 GRN 靶基因、系统特异调控边和命运信息量信号；因此可以提出具体的系统和细胞类型读出。

例如：

- **Lef1**：可在 neural/Wnt-FGF 叙事中重点看 *Fgf15*，同时检查 erythroid/myoblast 系统中是否出现跨系统响应。
- **Pax3**：GRN 中直接连接 *Nrg1* 和 *Lef1*，适合检查 neural patterning、muscle precursor 和 primitive erythroid 的共同偏移。
- **Satb2**：在 cardiac muscle、myotube 和 neural 中有系统边，适合观察结构重塑、分化成熟和命运稳定。

- **Eya1/Eya4**: 系统覆盖广，尤其在 erythroid 和 neural 中突出，适合作为跨系统协调因子的验证案例。
- **Dach2**: 在 myoblast 和 neural 中均突出，可连接肌生成与神经相关发育模块。




图 3: 原 OT+GRN 结果中的 TF-系统特异调控强度。颜色表示该 TF 在对应系统/细胞类型中的系统特异边绝对权重总和。




图 4: 基于原 OT+GRN 证据汇总的 TF 发育影响排序。该图仅为解释性证据排序，不是新预测模型。

9 从原型到正式模型的逐步执行计划

9.1 阶段一：数据子集与基因集合

1. 从原始 H5AD 导出 neural、mesodermal、reproductive 三个系统的小型 AnnData 子集。
2. 每个系统保留 TS12–TS23 或 TS14–TS20 主窗口。
3. 基因集合保留 HVG、TF、marker、pathway genes，规模控制在 2000–5000 个基因。
4. 固定每个子集的细胞数、阶段数、donor、cell type 和基因列表，保证后续比较口径一致。

9.2 阶段二：正常发育虚拟细胞

1. 训练或加载 cell encoder，将表达矩阵映射到 latent state。
2. 对相邻 stage 计算 mini-batch OT coupling。
3. 使用 barycentric projection 生成伪下一步目标。
4. 训练 transition operator $F_{\theta}(x_i^t, t, c_i)$ 。
5. rollout 1–5 步并解码回表达矩阵。
6. 使用 heldout stage、heldout cell type 和 heldout transition 评估正常发育生成能力。

9.3 阶段三：刺激输入和反馈恢复

1. 实现 TF knockdown、TF overexpression、pathway activation/inhibition 三类 stimulus embedding。
2. 将 RDEG 的 GRN 或外部 prior 转成 feedback head 的稀疏约束。
3. 用扰动条件下的多步 rollout 计算 response amplitude、feedback cost、fate displacement 和 recovery probability。
4. 设计 no OT、no GRN、no feedback、no stimulus embedding 等消融实验。

9.4 阶段四：外部扰动验证

1. 接入公开 perturbation 数据，优先考虑和 neural、Wnt、RA、FGF、PGC-like 或 differentiation 相关的数据。
2. 与 CellOT、CPA、scGPT/Geneformer embedding + MLP 进行比较。

3. 指标包括 DEG overlap、logFC Spearman、Wasserstein distance、cell-state transition accuracy 和 pathway recovery。
4. 若条件允许，设计 2–3 个小规模实验验证：RA/Wnt 敏感窗口、Lef1 perturbation、Glis3/Tbx4 rescue。

10 风险控制

1. **真实扰动数据不足**：当前结果必须标注为 counterfactual simulation 或 proxy，不能写成已验证事实。
2. **虚拟细胞概念过大**：论文中应限定为 embryo-context developmental virtual cell，而不是 universal virtual cell。
3. **与 RDEG 重叠**：第一篇讲阶段重建和群体流，第二篇讲单细胞刺激响应和反馈恢复。
4. **模型过重**：先完成 DevVCell-lite 和轻量 cell-level model，再评估是否引入 scGPT、Geneformer 或更大模型 embedding。

11 当前结论

本次结果支持将 TS14–TS19 作为重点敏感窗口继续推进，同时提示 Theiler stage 12 也需要作为早期高变化阶段单独建模。扰动优先级上，Satb2、Rfx4、Eya1、Lef1 和 Prox1 是当前最值得进入下一步训练或验证的候选。更重要的是，原 OT+GRN 结果已经能够进一步解释 TF 调控作用的系统落点：Eya1、Lef1、Prdm16、Satb2、Dach2、Pax3 等 TF 的系统特异调控边分别指向 erythroid、myoblast、primitive erythroid、neural 和 cardiac muscle 等发育过程。下一阶段应在保持原 OT+GRN 框架的基础上，把这些系统级解释转化为更具体的细胞类型读出和实验验证设计。

参考文献

- [1] 本项目内部报告：RDEG 宏观–微观联合推演框架的可验证发现汇总：GRN 新边、谱系推演、基因扰动与滚动预测误差窗口，2026。
- [2] 本项目内部报告：单细胞胚胎发育图谱中的低代价群体重排、基因调控动力学与严格谱系证据边界：从宏观发育重建到 PGC–Leydig 生殖系统案例的统一分析，2026。
- [3] Schiebinger, G. et al. Optimal-transport analysis of single-cell gene expression identifies developmental trajectories in reprogramming. *Cell*, 2019.
- [4] Cuturi, M. Sinkhorn distances: Lightspeed computation of optimal transport. *Advances in Neural Information Processing Systems*, 2013.

- [5] Bunne, C. et al. Learning single-cell perturbation responses using neural optimal transport. *Nature Methods*, 2023.
- [6] Lotfollahi, M. et al. Predicting cellular responses to complex perturbations in high-throughput screens. *Molecular Systems Biology*, 2023.
- [7] Kamimoto, K. et al. Dissecting cell identity via network inference and in silico gene perturbation. *Nature*, 2023.
- [8] Theodoris, C. V. et al. Transfer learning enables predictions in network biology. *Nature*, 2023.
- [9] Cui, H. et al. scGPT: toward building a foundation model for single-cell multi-omics using generative AI. *Nature Methods*, 2024.